Евгений Борисов

кроссвалидация

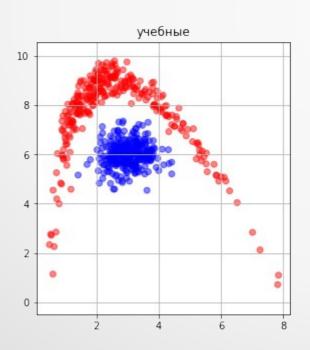
```
разделение данных на части (классы)
Учебный набор: [ объект, ответ ]
Задача: классификатор
              объект → вектор-признак → результат
Обучение: минимизация ошибки
                   ошибка = результат - правильный ответ
Критерий остановки:
         достигнут порог значения ошибки,
            и/или порог количества циклов
```

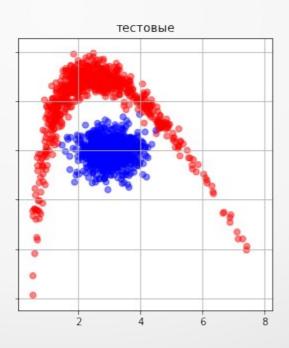
разделяем набор данных

- учебный
- тестовый

недообучение (underfitting) большая ошибка на учебном наборе

переобучение (overfitting) малая ошибка на учебном наборе большая ошибка на тестовом наборе



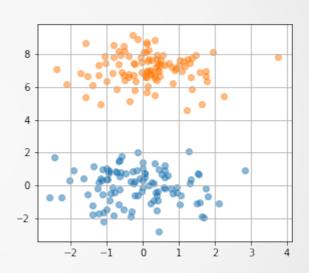


классификация - задача разделения объектов на классы

$$X \subset \mathbb{R}^n$$
 - объекты

$$Y \in \{0,1\}$$
 - метки классов

$$p \in [0,1]$$
 - оценка



$$a: X o p$$
 - считаем оценку

$$y = \begin{cases} 0, p < b -$$
если оценка выше порога то объект принадлежит «первому» классу

метрики качества

```
- погрешность (accuracy)
- матрица ошибок ( confusion matrix )
```

- точность (precision)
- полнота (recall)
- F-мера
- ROC/AUC

погрешность (accuracy)

правильные ответы / всего примеров

Accuracy это оценка только для сбалансированного датасета, т.е. количество примеров в классах почти одинаковое

Пример:

имеем датасет из 203 объектов

1. сбалансированный

100 позитивных 103 негативных

90 правильно предсказанных позитивных

10 ложно-негативных предсказаний 103 правильно предсказанных негативных

193 правильных ответов

193/203 = .95 accuracy

2. несбалансированный

6 позитивных 197 негативных

0 правильно предсказанных позитивных

197 правильно предсказанных негативных 6 ложно-негативных предсказаний

197 правильных ответов

197/203 = .97 accuracy

Пример:

тест на болезнь «зеленуху» имеет вероятность ошибки 0.1 (как позитивной, так и негативной)

зеленухой болеет 10% населения.

Какая вероятность того, что человек болен зеленухой, если у него позитивный результат теста?

Подсказка: формула Байеса

$$P(\text{болен} | +) = \frac{P(+|\text{болен})P(\text{болен})}{P(+|\text{болен})P(\text{болен}) + P(+|\text{здоров})P(\text{здоров})}$$

Подсказка: формула Байеса

$$P(\text{болен} | +) = \frac{P(+|\text{болен})P(\text{болен})}{P(+|\text{болен})P(\text{болен}) + P(+|\text{здоров})P(\text{здоров})}$$

OTBET: (0.9*0.1) / (0.9*0.1 + 0.1*0.9) = 0.5

Подсказка: формула Байеса

$$P(\text{болен} | +) = \frac{P(+|\text{болен})P(\text{болен})}{P(+|\text{болен})P(\text{болен}) + P(+|\text{здоров})P(\text{здоров})}$$

OTBET: (0.9*0.1) / (0.9*0.1 + 0.1*0.9) = 0.5

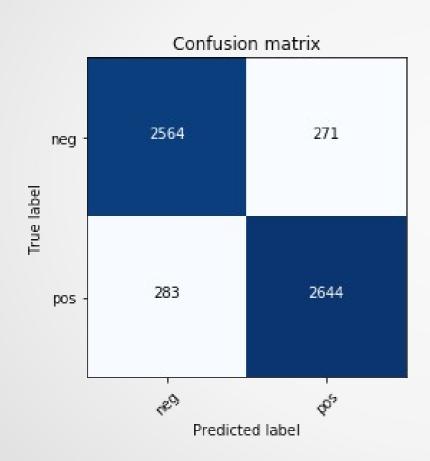
Замечание о корректности этого результата:

анализы проводят, когда есть подозрение на какую-то болезнь,

поэтому вероятность болезни надо вычислять по этой «подозрительной» группе.

это понижает требования к точности прибора...

матрица ошибок (confusion matrix)



два класса — четыре группы

- ТР истинно положительные
- TN истинно отрицательные
- FP ложно положительные
- FN ложно отрицательные

точность (precision)

TP/(TP + FP)

доля истинно позитивных относительно всех объектов, которые классификатор определил как позитивные

точность (precision)

TP/(TP+FP)

доля истинно позитивных относительно всех объектов, которые классификатор определил как позитивные

полнота (recall)

TP/(TP + FN)

доля истинно позитивных, найденных классификатором, относительно всех истинно позитивных

точность (precision)

TP/(TP+FP)

доля истинно позитивных относительно всех объектов, которые классификатор определил как позитивные

полнота (recall)

TP/(TP + FN)

доля истинно позитивных, найденных классификатором, относительно всех истинно позитивных

С ростом полноты точность может снижаться

точность (precision)

TP/(TP+FP)

доля истинно позитивных относительно всех объектов, которые классификатор определил как позитивные

полнота (recall)

TP/(TP + FN)

доля истинно позитивных, найденных классификатором, относительно всех истинно позитивных

С ростом полноты точность может снижаться

F-мера

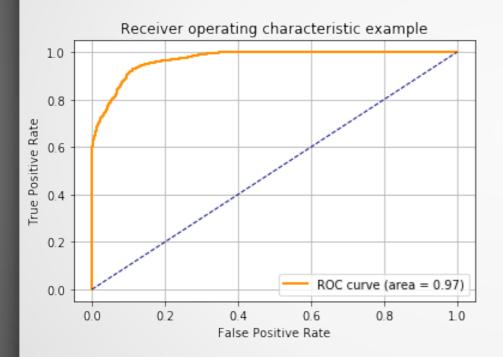
(precision*recall) / (precision+recall) усреднение точности и полноты

Пример classification_report

pr	ecision	recall	f1-score	support
0 1		0.90 0.90	0.90 0.91	2835 2927
avg / total	0.90	0.90	0.90	5762

ROC - receiver operating characteristic, рабочая характеристика приёмника

ROC - зависимость полноты (TPR) от доли ложно-негативных (FPR)



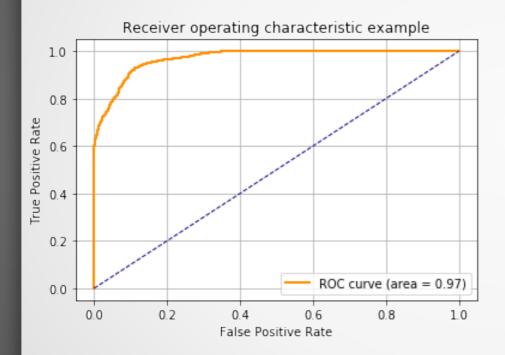
TPR=TP/(TP+FN) полнота(recall), доля позитивных, найденных классификатором, относительно всех позитивных

FPR=FP/(FP+TN) доля негативных предсказанных неверно

AUC - area under ROC curve, площадь под ROC-кривой характеристика качества классификации

ROC - receiver operating characteristic, рабочая характеристика приёмника

ROC - зависимость полноты (TPR) от доли ложно-негативных (FPR)



TPR=TP/(TP+FN) полнота(recall), доля позитивных, найденных классификатором, относительно всех позитивных

FPR=FP/(FP+TN) доля негативных предсказанных неверно

AUC - area under ROC curve, площадь под ROC-кривой характеристика качества классификации

способ построения ROC

Таб.1 результаты классификатора

id	оценка	класс
1	0.5	0
2	0.1	0
3	0.2	0
4	0.6	1
5	0.2	1
6	0.3	1
7	0.0	0

Табл. 1

способ построения ROC

Таб.1 результаты классификатора

id	оценка	класс
1	0.5	0
2	0.1	0
3	0.2	0
4	0.6	1
5	0.2	1
6	0.3	1
7	0.0	0

Табл. 1

упорядочим строки табл. 1 по убыванию ответов алгоритма

id	оценка	класс
4	0.6	1
1	0.5	0
6	0.3	1
3	0.2	0
5	0.2	1
2	0.1	0
7	0.0	0

Табл. 2

способ построения ROC

Таб.1 результаты классификатора

id	оценка	класс
1	0.5	0
2	0.1	0
3	0.2	0
4	0.6	1
5	0.2	1
6	0.3	1
7	0.0	0

Табл. 1

упорядочим строки табл. 1 по убыванию ответов алгоритма

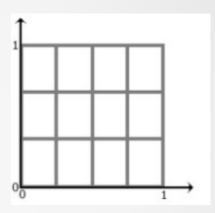
id	оценка	класс
4	0.6	1
1	0.5	0
6	0.3	1
3	0.2	0
5	0.2	1
2	0.1	0
7	0.0	0

Табл. 2

единичный квадрат на координатной плоскости,

разбить на m равных частей горизонтальными линиями, m - число 1 (m=3),

и на n – вертикальными, n – число нулей (n=4). получаем сетку на $m \times n$ блоков.



способ построения ROC

Таб.1 результаты классификатора

id	оценка	класс
1	0.5	0
2	0.1	0
3	0.2	0
4	0.6	1
5	0.2	1
6	0.3	1
7	0.0	0

Табл. 1

упорядочим строки табл. 1 по убыванию ответов алгоритма

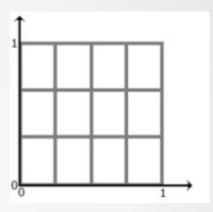
id	оценка	класс
4	0.6	1
1	0.5	0
6	0.3	1
3	0.2	0
5	0.2	1
2	0.1	0
7	0.0	0

Табл. 2

единичный квадрат на координатной плоскости,

разбить на m равных частей горизонтальными линиями, m - число 1 (m=3),

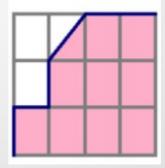
и на n – вертикальными, n – число нулей (n=4). получаем сетку на $m \times n$ блоков.



идем по строкам табл. 2 сверху вниз и прорисовывать на сетке линию из точки (0,0).

если метка класса 1, то делаем шаг вверх; если 0, то делаем шаг вправо.

если оценки равны, то мы делаем шаг в точку, которая на а блоков выше и b блоков правее, где а – число единиц в группе, b – число нулей в ней.



git clone https://github.com/mechanoid5/ml_lectorium.git
Александр Дьяконов AUC ROC (площадь под кривой ошибок)
Кривая ошибок http://www.machinelearning.ru



Вопросы?