Автоматическая обработка текстов на естественном языке. Метод частотного анализа.

Евгений Борисов

NLP частотный анализ

о языке и задача автоматической его обработки

обработка текстов на естественом языке (ЕЯ)

natural language processing (NLP)

NLU / natural language understatnding

NLG / natural language generation

SP / speech processing (recognition/generation)

NLP частотный анализ

обработка текстов на естественом языке

NLP/ NLU natural language understatnding

- natural entity recognition - распознавание именованных сущностей
- classification intent - классификация намерений
- sentiment analysis - оценка тона

NLP частотный анализ

метод частотного анализа

Какие задачи можно решать?

сортировка по заданным темам

определение авторства

определение тона текста

поиск похожих текстов

текст должен содержать слова в достаточном количестве

NLP частотный анализ

схема системы обработки текстов

подбор текстов для обучения

извлечение признаков из текста

обучение модели ML

тестирование результата

NLP частотный анализ

извлечение признаков из текста

определение языка

токенизация

очистка

составление словаря

частотный анализ текстов по словарю

(bag of words, BoW)

NLP частотный анализ

извлечение признаков из текста

<u>токенизация</u>

разбиения текста на отдельные слова
и/или словосочетания

10кг, АИ-97, к.ф.м.н.

n-gram - последовательность из n слов

```
Законодательная дума Хабаровского края (duma.khv.ru)

[ 'Законодательная', 'дума', 'Хабаровского', 'края', '(duma.khv.ru)' ]
```

NLP частотный анализ

извлечение признаков из текста

очистка

способ очистки зависит от задачи

NLP частотный анализ

извлечение признаков из текста

очистка

способ очистки зависит от задачи

удаление стоп-слов (предлоги и т.п.)

NLP частотный анализ

извлечение признаков из текста

<u>очистка</u>

способ очистки зависит от задачи

удаление стоп-слов (предлоги и т.п.)

удаление лишних символов (знаки препинания и т.п.)
«смайлики» - отдельное слово

NLP частотный анализ

извлечение признаков из текста

<u>очистка</u>

способ очистки зависит от задачи

удаление стоп-слов (предлоги и т.п.)

удаление лишних символов (знаки препинания и т.п.)
«смайлики» - отдельное слово

преобразование чисел, интернет ссылок и т.п.

NLP частотный анализ

извлечение признаков из текста

очистка

способ очистки зависит от задачи

удаление стоп-слов (предлоги и т.п.)

удаление лишних символов (знаки препинания и т.п.)
«смайлики» - отдельное слово

преобразование чисел, интернет ссылок и т.п.

лемматизация - приведение слов к нормальному виду
или
стеминг - выделение основ слов

NLP частотный анализ

извлечение признаков из текста

<u>очистка</u>

способ очистки зависит от задачи

удаление стоп-слов (предлоги и т.п.)

удаление лишних символов (знаки препинания и т.п.)
«смайлики» - отдельное слово

преобразование чисел, интернет ссылок и т.п.

лемматизация - приведение слов к нормальному виду
<u>или</u>
стеминг - выделение основ слов

```
Законодательная дума Хабаровского
края (duma.khv.ru) Состоялось
очередное заседание Думы На последнем
перед каникулами очередном заседании
Законодательной Думы Хабаровского
края, состоявшемся 28
```

```
['законодательн',
 'дум',
 'хабаровск',
 'кра',
 'url',
 'состоя',
 'очередн',
 'заседан',
 'дум',
 'последн',
 'перед',
 'каникул',
 'очередн',
 'заседан',
 'законодательн',
 'дум',
 'хабаровск',
 'кра',
 'состоя',
 'digit',
```

NLP частотный анализ

извлечение признаков из текста
<u>составление словаря</u>

из очищенного текста извлекаем словарь

```
[
 'digit',
 'url',
 'администрац',
 'большинств',
 'бурн',
 'бюджетн',
 'верхнебуреинск',
 'власт',
 'возьмет',
 'войдет',
 'вопрос',
 'врем',
 'втор',
 'вызва',
 'год',
  ...
]
```

NLP частотный анализ

извлечение признаков из текста

<u>частотный анализ текстов по словарю</u>

простой частотный анализ
считаем в тексте t количество повторов x_i
каждого слова v_i из словаря V

текст должен содержать слова в достаточном количестве

NLP частотный анализ

извлечение признаков из текста

<u>частотный анализ текстов по словарю</u>

простой частотный анализ
считаем в тексте t количество повторов x_i
каждого слова v_i из словаря V

значения x зависят от размера текста t,
чем больше текст тем больше повторов

нормализованны частотный анализ (TF, term frequency)
значения частоты x делятся на общее число слов в тексте t.

$$TF(t,V) = x(t,V) / size(t)$$

NLP частотный анализ

извлечение признаков из текста
частотный анализ текстов по словарю

Удалять часто употребляемые слова или нет?

NLP частотный анализ

извлечение признаков из текста
частотный анализ текстов по словарю

Удалять часто употребляемые слова или нет?

TF-IDF - компромиссный вариант формирования вектор-признаков.

не выбрасывает часто употребляемые слова из словаря
но уменьшает их вес в вектор-признаке

NLP частотный анализ

извлечение признаков из текста
частотный анализ текстов по словарю

Удалять часто употребляемые слова или нет?

TF-IDF - компромиссный вариант формирования вектор-признаков.

не выбрасывает часто употребляемые слова из словаря
но уменьшает их вес в вектор-признаке

коэффициент обратной частоты (IDF, inverse document frequency)
чем чаще встречается слово тем меньше значение его IDF

$$IDF(v) = \log size(T) / size(T(v))$$

количество текстов T
разделить на
количество текстов T содержащих слово v

$$TF\text{-}IDF(t,T,v) = TF(t,v) * IDF(v,T)$$

NLP частотный анализ

извлечение признаков из текста
частотный анализ текстов по словарю

хэш-векторизация

заменяем слова на их хэш ограниченной длины

сокращаем размер словаря
и число признаков

экономия ресурсов для больших датасетов

NLP частотный анализ

практическое применение

сортировка по заданным темам - классификация
собираем и размечаем тексты
чистим текст
применяем частотный анализ
обучаем классификатор
тестируем

NLP частотный анализ

практическое применение

сортировка по заданным темам - классификация
собираем и размечаем тексты
чистим текст
применяем частотный анализ
обучаем классификатор
тестируем

определение авторства - классификация
собираем и размечаем тексты
чистим текст (частота употребления предлогов - важный признак)
применяем частотный анализ
обучаем классификатор
тестируем

NLP частотный анализ

практическое применение

сортировка по заданным темам - классификация
собираем и размечаем тексты
чистим текст
применяем частотный анализ
обучаем классификатор
тестируем

определение авторства - классификация
собираем и размечаем тексты
чистим текст (частота употребления предлогов - важный признак)
применяем частотный анализ
обучаем классификатор
тестируем

поиск похожих текстов - кластеризация
собираем тексты
чистим текст
применяем частотный анализ
выполняем кластеризацию (размечаем тексты)

NLP частотный анализ

Литература

git clone *https://github.com/mechanoid5/ml_nlp.git*

К.В. Воронцов Вероятностные тематические модели коллекций текстовых документов.

Евгений Борисов Автоматизированная обработка текстов на естественном языке, с использованием инструментов языка Python
http://mechanoid.su/ml-text-proc.html

Sebastian Raschka Python Machine Learning - Packt Publishing Ltd, 2015