Евгений Борисов

Языковая модель

- предсказываем следующее слово на основе предыдущих
- оценка (вероятность) совместимости цепочки слов

Оценка цепочки слов (биграммная модель):

$$p(w_1...w_n) = \prod_{k=1}^n p(w_k|w_{k-1})$$

$$p(w_n|w_{n-1}) = \frac{C(w_{n-1}w_n)}{C(w_{n-1})}$$

Приложения

распознавание речи

определение частей речи

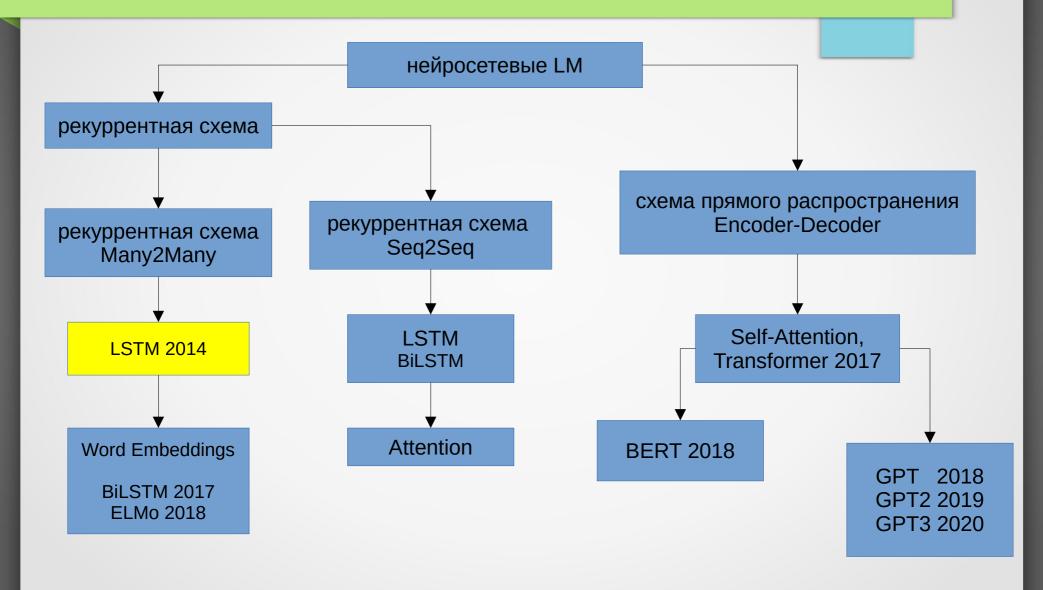
генерация текстов

извлечение терминов

поиск и коррекция семантических ошибок

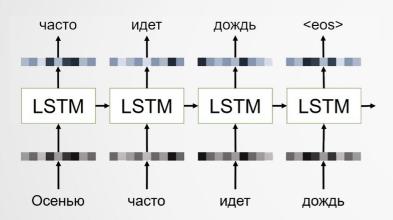
Р - вероятность совместного использования слов

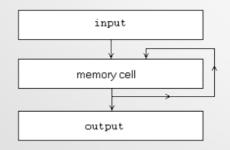
C(w) - количество слов w в тексте

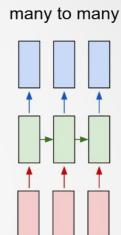


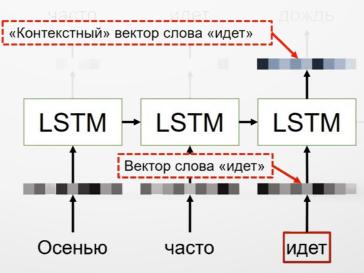
Простая схема с рекуррентной сетью

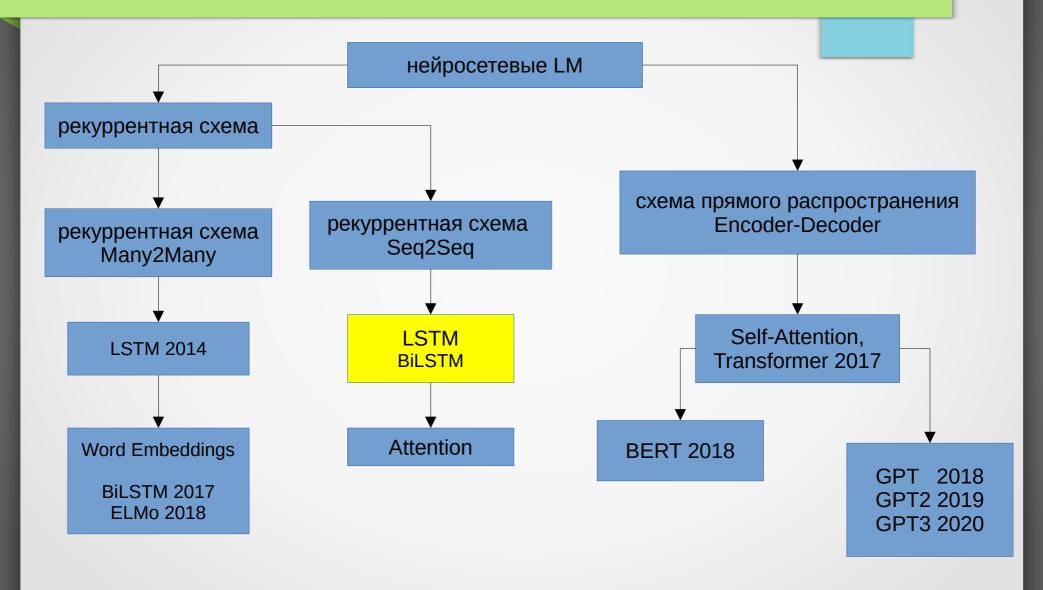
Предсказываем следующее слово по предыдущему контексту получаем word embedding, который учитывает левый контекст



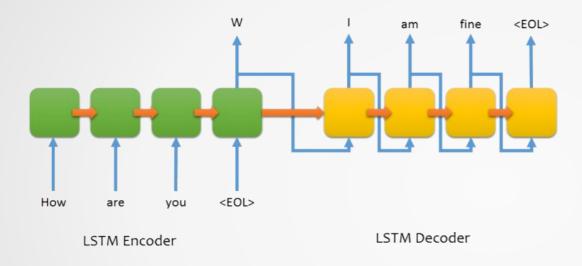






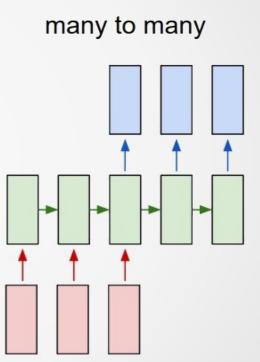


Рекуррентная схема SEQ2SEQ



пара рекуррентных неросетей

- кодировщик,
 формирует внутреннее представление
- декодировщик, авторегрессионная модель, разворачивает состояние энкодера



git clone https://github.com/mechanoid5/ml nlp.git

Нейчев Радослав Прикладное машинное обучение 3. Machine translation. Лекторий ФПМИ, 2020 https://www.youtube.com/watch?v=6HibilFua-U

Турдаков Д.Ю. Основы обработки текстов. ИСП РАН, 2017,2021

https://www.youtube.com/playlist?list=PL5cBzMoPJgCUn6TbfhqilyToW5lScOdd3

https://www.youtube.com/playlist?list=PL5cBzMoPJgCXFdSvWaunOy4cILirW11MD